

ESCUELA DE DERECHO • PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

Documento de trabajo para el Consejo de Profesores

Informe sobre inteligencia artificial generativa y enseñanza del Derecho

Edición 2026

Preparado para la Dirección de la Escuela de Derecho

Diego Hernán Ojeda Cifuentes

Licenciado en Ciencias Jurídicas

Valparaíso, septiembre de 2026

Índice

I. Resumen	4
II. Objetivos.....	6
1. El problema.....	6
2. Objeto del informe	6
3. Relación con el otro informe	6
4. Lo que el informe no hace.....	7
III. Metodología.....	8
1. Qué se examinó	8
2. Cómo se ponderó cada estudio.....	8
3. Cómo se expresa el grado de certeza	8
4. Limitaciones del procedimiento	9
5. Nota sobre la elaboración del documento	9
IV. La extensión del uso y lo que no significa	10
1. Dos curvas que no deben confundirse.....	10
2. Lo que los estudiantes declaran sobre su formación	10
3. El profesorado	11
4. La política declarada y la política vigente	12
5. Consecuencia del capítulo	12
V. La evaluación escrita y su valor probatorio.....	13
1. El experimento de Reading	13
2. Por qué la detección automática no resolvió el problema	13
3. Lo que miden las cifras disciplinarias.....	14
4. La respuesta de los dos carriles	15
5. Qué instrumentos conservan valor probatorio	15
VI. El efecto sobre el aprendizaje	16
1. Dos ensayos que parecen contradecirse.....	16
2. La regla que ambos sugieren.....	16
3. La distancia entre el rendimiento percibido y el medido.....	17
4. Homogeneización y desempeño desigual	17
5. Lo que no se sabe	18
VII. Competencias, profesorado y equidad.....	19
1. Qué capacidades quedan y cuáles se desplazan	19

2. La distancia entre el rendimiento y el criterio.....	19
3. El profesorado como condición de todo lo anterior	20
4. La brecha de aprendizaje asistido	20
5. Consecuencia del capítulo	21
VIII. El Derecho como caso crítico	22
1. Por qué el Derecho está más expuesto	22
2. La fiabilidad medida de las herramientas jurídicas	22
3. Los tribunales ante las citas inventadas	23
4. El efecto sobre el aprendizaje jurídico	24
5. Lo que la evidencia jurídica no cubre	24
6. La escritura jurídica y los instrumentos que resisten.....	25
7. El acceso a la profesión	26
8. Qué están haciendo las facultades de Derecho	27
9. El panorama iberoamericano.....	27
IX. Respuestas institucionales y sus límites.....	29
1. Cuatro modelos de gobernanza.....	29
2. Un contraejemplo de escala	29
3. Tres casos de contraste.....	30
4. Enseñar sobre la inteligencia artificial, con ella o para trabajar con ella.....	30
5. La profundidad del cambio	30
X. Consecuencias para una escuela de Derecho	32
1. Advertencia previa sobre el alcance de este capítulo	32
2. Las cinco medidas	32
3. El riesgo principal y cómo reconocerlo a tiempo.....	34
4. El contexto chileno y una oportunidad propia.....	34
XI. Conclusiones.....	35
Bibliografía	37
1. Estudios experimentales	37
2. Estudios y análisis chilenos.....	38
3. Encuestas y registros.....	38
4. Documentos institucionales y normativos	38
5. Trabajos retractados o corregidos, citados como antecedente.....	38
Anexo. Solidez de la evidencia y nota sobre la elaboración	40
1. Los estudios que sostienen las conclusiones	40

2. Qué se verificó y qué no.....	41
3. Límites del procedimiento	41
4. Nota sobre la elaboración del documento	41

I. Resumen

Este informe examina qué efectos ha tenido la inteligencia artificial generativa sobre la enseñanza universitaria y, en particular, sobre la enseñanza del Derecho, y qué consecuencias se siguen de la evidencia publicada hasta agosto de 2026. Acompaña al informe sobre el uso de inteligencia artificial en las escuelas de Derecho chilenas, que describe lo que las instituciones hacen; este documento examina qué se sabe sobre el resultado de hacerlo.

El punto de partida es un resultado experimental antes que una apreciación sobre la tecnología. En 2024 un equipo de la Universidad de Reading insertó trabajos generados íntegramente por un modelo de lenguaje en el sistema real de exámenes de cinco módulos de Psicología, con corrección ciega a cargo de los propios evaluadores del curso. El 94 % de esas entregas no fue detectado y obtuvo, en promedio, calificaciones superiores a las de los estudiantes reales. De ahí se sigue que la calificación de un trabajo escrito no supervisado ha dejado de ser información fiable sobre quien lo entrega, y ello con independencia de que haya o no intención de engañar.

La extensión del uso hace inviable la respuesta prohibitiva. La serie del Higher Education Policy Institute muestra que la proporción de estudiantes de grado británicos que declara emplear inteligencia artificial generativa en trabajos evaluados pasó del 53 % en 2024 al 88 % en 2025 y al 94 % en 2026. La proporción que declara insertar texto generado directamente en la entrega creció también, aunque sigue siendo minoritaria: del 3 % al 12 % en el mismo período. Ambas cifras deben leerse por separado, porque la primera describe una práctica generalizada y la segunda una conducta que sí compromete la evaluación.

La respuesta disciplinaria tampoco resuelve el problema. Los sistemas británicos prueban del orden de siete casos de mala conducta con inteligencia artificial por cada mil estudiantes, frente al 94 % que declara usarla. La detección automática, por su parte, produce falsos positivos que recaen de manera desigual: un estudio de Stanford encontró una tasa media del 61,3 % sobre ensayos escritos por hablantes no nativos de inglés, y al menos doce universidades de primer orden han desactivado esas herramientas. La cuestión dejó de ser de integridad académica para pasar a ser de validez de los instrumentos de evaluación.

Sobre el aprendizaje, la evidencia disponible es escasa y apunta en una dirección precisa. Dos ensayos aleatorizados publicados en 2025 parecen contradecirse, aunque en rigor no lo hacen. En Harvard, un tutor construido con andamiajes redactados por expertos y restricciones explícitas para no entregar la respuesta produjo el doble de ganancias de aprendizaje que una clase de aprendizaje activo bien ejecutada. En Turquía, con cerca de mil estudiantes de secundaria, el acceso libre al mismo tipo de modelo mejoró el rendimiento un 48 % mientras la herramienta estaba disponible y, al retirarla, dejó a esos estudiantes un 17 % por debajo de quienes nunca la habían tenido. Lo que separa ambos resultados es el diseño de la tarea y no el acceso a la herramienta.

El Derecho constituye un caso crítico por dos rasgos propios del oficio. El primero es que verificar que una fuente existe, dice lo que se afirma y sigue vigente forma parte del trabajo jurídico, y es la operación que estas herramientas ejecutan peor. La evaluación de Magesh y otros, publicada en el *Journal of Empirical Legal Studies*, encontró que las herramientas

jurídicas comerciales entregan contenido inventado entre el 17 % y el 33 % de las consultas, y los modelos generales sin recuperación jurídica especializada, en el 43 %. El segundo es que el abogado responde personalmente por lo que firma. El registro de resoluciones judiciales en que un tribunal constató el uso de contenido inventado pasó de más de mil doscientos casos a comienzos de 2026 a mil novecientos ochenta y uno el 28 de agosto del mismo año.

Los efectos sobre el aprendizaje jurídico no son uniformes. El estudio de Choi y Schwarcz encontró que el acceso a un modelo de lenguaje elevó en torno a cuarenta y cinco puntos percentiles el desempeño de los estudiantes de peor rendimiento previo y empeoró el de los de mejor rendimiento previo. La herramienta aumenta la velocidad de manera amplia y consistente, y mejora la calidad del análisis de manera ligera e inconsistente.

En materia de respuestas institucionales, el informe examina treinta instituciones de diez países. Ninguna alcanza una transformación coordinada de currículo, evaluación, docencia, competencias, infraestructura y gobernanza. El tamaño del despliegue tampoco anticipa la profundidad del cambio: el caso de mayor escala examinado, con más de cuatrocientos setenta mil estudiantes y un contrato de trece millones de dólares anuales, registra en su propia encuesta interna que el 52 % de su profesorado percibe un efecto negativo sobre su docencia.

De todo ello se siguen cinco decisiones que una escuela de Derecho puede adoptar, ordenadas por costo en el capítulo X. Cuatro de ellas son documentales o de criterio y pueden adoptarse en el plazo de un año académico. La quinta consiste en presupuestar horas docentes para evaluación oral y diseño de tareas, y es la que determina si las anteriores producen algún resultado. El principal riesgo de la reforma evaluativa no es pedagógico ni tecnológico, sino presupuestario.

Una advertencia final sobre la evidencia misma. En abril de 2026 una revista retractó el metaanálisis de Wang y Fan, que era la referencia más citada a favor de efectos positivos grandes de la inteligencia artificial sobre el aprendizaje, después de acumular doscientas sesenta y seis citas. El motivo fue la agrupación de estudios demasiado heterogéneos para combinarse. Cualquier documento institucional sobre esta materia fechado antes de esa retractación merece releerse con ese dato a la vista.

II. Objetivos

1. El problema

Durante siglos el trabajo escrito que un estudiante entregaba cumplió cuatro funciones simultáneas. Le enseñaba, porque escribir obliga a ordenar lo que se sabe. Producía algo con valor propio, que en Derecho podía ser un informe, una minuta o un comentario de jurisprudencia. Lo entrenaba en las operaciones del oficio, entre ellas buscar, verificar, citar y argumentar. Y acreditaba ante el profesor que sabía hacerlo. La inteligencia artificial generativa automatizó la cuarta función y, al hacerlo, la separó de las otras tres.

La consecuencia alcanza a toda la enseñanza universitaria, más allá de los casos de mala conducta. Un estudiante que emplea estas herramientas de manera razonable y declarada entrega también un producto que ya no informa sobre lo que sabe hacer sin ellas. El profesor sigue recibiendo un texto, y ese texto ha dejado de ser evidencia suficiente de la capacidad de quien lo firma.

El Derecho recibe esa consecuencia de manera más directa que otras disciplinas, por dos razones que el capítulo VIII desarrolla. La primera es que la verificación de fuentes, que estas herramientas ejecutan mal, no es una formalidad del trabajo jurídico sino una parte de él. La segunda es que el abogado responde personalmente por el contenido de lo que suscribe, de modo que el error que en otro campo produce una mala calificación en este produce una sanción procesal o disciplinaria.

2. Objeto del informe

El informe se propone tres cosas.

La primera es exponer qué dice la evidencia publicada sobre el uso de inteligencia artificial generativa en la educación superior, sobre su efecto en el aprendizaje y sobre la validez de los instrumentos de evaluación, distinguiendo en cada caso qué está bien establecido y qué no.

La segunda es examinar el caso particular del Derecho, tanto en lo que se refiere a la fiabilidad de las herramientas jurídicas como a sus efectos sobre la formación y sobre el acceso a la profesión.

La tercera es derivar de ese examen las decisiones que una escuela de Derecho puede adoptar, ordenadas por costo y separando lo que la evidencia sostiene de lo que constituye una opción normativa razonable pero discutible.

3. Relación con el otro informe

Este documento acompaña al informe sobre el uso de inteligencia artificial en las escuelas de Derecho chilenas, y ambos se leen mejor juntos. Aquel describe lo que once facultades chilenas han construido, con qué grado de formalización y desde cuándo. Este examina qué se sabe sobre el efecto de construir esas capacidades.

La relación entre ambos se aprecia en un punto concreto. El primer informe constata que ninguna de las once facultades ha publicado una medición del efecto de sus iniciativas sobre

el aprendizaje. Este documento muestra que la evidencia internacional sobre esa materia es escasa, reciente y en parte poco fiable, de modo que la ausencia chilena no se corrige consultando la literatura extranjera.

4. Lo que el informe no hace

El documento no constituye una revisión sistemática. No se declaró un protocolo de búsqueda previo, no se registró la estrategia empleada ni se aplicaron criterios de inclusión y exclusión formalizados, de modo que no cabe atribuirle la exhaustividad que ese método garantiza. El capítulo III precisa el procedimiento seguido y el anexo detalla sus límites.

El documento tampoco emite una recomendación sobre adquirir o dejar de adquirir tecnología. Las decisiones del capítulo X son de diseño evaluativo y curricular, y ninguna requiere comprar software.

El documento no se pronuncia, por último, sobre la conveniencia moral del uso de inteligencia artificial en la formación jurídica. Describe lo que ocurre, lo que se ha medido y lo que se sigue de ambas cosas.

III. Metodología

1. Qué se examinó

El informe analiza evidencia publicada entre noviembre de 2022, fecha en que los modelos de lenguaje de uso general alcanzaron difusión masiva, y agosto de 2026. El material reunido comprende cuatro clases de fuentes, que no tienen el mismo valor probatorio y que el documento distingue cada vez que las emplea.

La primera clase son los estudios experimentales, es decir, ensayos aleatorizados y experimentos de campo que comparan un grupo que recibe la intervención con otro que no la recibe. Son los únicos que permiten atribuir un efecto a una causa, y son también los más escasos.

La segunda clase son las encuestas y los registros administrativos, que describen prácticas declaradas o sancionadas. Informan sobre extensión y tendencia, sin alcanzar al efecto. Las encuestas citadas en este informe son autoinformadas y varias emplean muestras autoseleccionadas, de modo que sus cifras describen a quienes respondieron antes que a la población de referencia.

La tercera clase son los documentos institucionales, esto es, políticas, reglamentos, memorias y comunicaciones de universidades. Acreditan lo que una institución decidió y publicó, sin informar sobre lo que ocurre en sus aulas.

La cuarta clase son los análisis y comentarios de autor, que el informe emplea para situar un problema, nunca para sostener una afirmación empírica.

2. Cómo se ponderó cada estudio

Las afirmaciones del informe se apoyan en tres criterios de ponderación, aplicados en el orden que sigue.

El primer criterio es el diseño del estudio. Un ensayo aleatorizado pesa más que un estudio observacional, y este más que un autoinforme. El informe indica el diseño cada vez que cita una cifra relevante.

El segundo criterio es la población estudiada. Un resultado obtenido con estudiantes de secundaria no se traslada sin más a estudiantes universitarios, y uno obtenido con estudiantes de Derecho estadounidenses no se traslada sin más al caso chileno. El informe consigna la población de cada estudio que emplea.

El tercer criterio es la independencia del equipo investigador. Los estudios financiados o ejecutados por proveedores de la tecnología evaluada reciben menor peso que los realizados por equipos sin interés en el resultado. El informe señala esa circunstancia cuando concurre.

3. Cómo se expresa el grado de certeza

Este documento evita las etiquetas de confianza y las escalas de solidez que suelen acompañar a los informes de evidencia, porque tienden a dar apariencia de precisión a juicios

que no la tienen. En su lugar, el grado de certeza se expresa en la propia redacción, mediante fórmulas cuyo sentido se fija aquí una vez.

Cuando el informe afirma que algo «está establecido» o «se ha medido», existe al menos un estudio experimental publicado en revista revisada por pares que lo sostiene. Cuando afirma que la evidencia «sugiere» o «apunta», existen resultados convergentes de diseños más débiles. Cuando afirma que algo «se ha declarado» o «se ha informado», la fuente es un autoinforme o un documento institucional. Y cuando afirma que algo «no consta» o «no se localizó», la búsqueda no lo encontró, sin que ello pruebe su inexistencia.

4. Limitaciones del procedimiento

El informe no es una revisión sistemática ni debe presentarse como tal. No hubo protocolo de búsqueda declarado con antelación, ni registro de la estrategia, ni criterios de inclusión y exclusión formalizados, ni doble revisión independiente de los estudios incorporados. La consecuencia es que no puede descartarse la omisión de trabajos relevantes ni un sesgo de selección en favor de los resultados más difundidos.

Tres advertencias concretas afectan a estudios que el informe cita y conviene anticiparlas aquí, porque han circulado con frecuencia sin ellas.

La primera se refiere al experimento de Bastani y otros, publicado en 2025. Se realizó con estudiantes de secundaria en Turquía, fuera por tanto de la población universitaria, y la revista que lo publicó emitió una corrección el 20 de agosto de 2025. Ambas circunstancias se indican cada vez que el estudio se emplea.

La segunda se refiere al metaanálisis de Wang y Fan, retractado el 22 de abril de 2026 tras acumular doscientas sesenta y seis citas. El informe no utiliza sus cifras y lo menciona únicamente como antecedente sobre el estado de la literatura.

La tercera se refiere al estudio de METR sobre productividad de desarrolladores, publicado en julio de 2025. Sus propios autores lo califican hoy de documento histórico, dada la velocidad con que cambiaron las herramientas evaluadas, y el informe lo emplea con esa advertencia.

5. Nota sobre la elaboración del documento

El informe se preparó con apoyo de herramientas de inteligencia artificial generativa en tareas de búsqueda preliminar, ordenación de material y redacción de versiones de trabajo. El autor verificó personalmente las cifras, los diseños y las poblaciones de los estudios citados contra su publicación original o su registro bibliográfico, y responde por el contenido del documento. El anexo detalla qué se verificó en cada caso.


IV. La extensión del uso y lo que no significa

1. Dos curvas que no deben confundirse

La cifra que más circula sobre esta materia es la proporción de estudiantes que emplea inteligencia artificial generativa, y suele citarse sin la que debería acompañarla. El Higher Education Policy Institute encuesta anualmente a estudiantes de grado británicos y ha publicado tres oleadas comparables. La proporción que declara emplear estas herramientas en trabajos evaluados pasó del 53 % en 2024 al 88 % en 2025 y al 94 % en 2026; la última oleada encuestó a 1.054 estudiantes.¹

La segunda curva mide algo distinto. En la misma serie, la proporción que declara insertar texto generado directamente en el trabajo entregado pasó del 3 % al 8 % y al 12 %. El gráfico 1 presenta ambas series juntas.

Gráfico 1. Uso de inteligencia artificial en trabajos evaluados y entrega directa de texto generado



Fuente: Higher Education Policy Institute, oleadas de 2024, 2025 y 2026. Encuesta autoinformada a estudiantes de grado del Reino Unido; la oleada de 2026 corresponde a 1.054 respuestas.

La distancia entre ambas curvas ordena el problema. La primera describe una práctica que alcanza a casi toda la población estudiantil y que comprende operaciones de muy distinta naturaleza, desde pedir una explicación de un concepto hasta corregir la redacción de un párrafo. Prohibirla equivaldría a legislar sobre una conducta generalizada e inobservable. La segunda describe la delegación completa de la producción del texto, que sigue siendo minoritaria y que sí compromete el valor de la evaluación. Tratar al 94 % como sospechoso conduce a un error de política tan grave como ignorar al 12 %.

2. Lo que los estudiantes declaran sobre su formación

La misma encuesta aporta tres datos sobre la relación entre estudiantes e institución que conviene registrar. Solo el 38 % declara que su universidad le provee herramientas de

¹HIGHER EDUCATION POLICY INSTITUTE (2024, 2025 y 2026): *Student Generative AI Survey*. Las tres oleadas son autoinformadas y corresponden a estudiantes de grado del Reino Unido. La oleada de 2026 recogió 1.054 respuestas en diciembre de 2025.

inteligencia artificial. El 68 % considera que las competencias en esta materia serán esenciales para su futuro profesional, mientras que solo el 48 % percibe que el profesorado le ayuda a desarrollarlas. El 65 %, por último, afirma que su evaluación cambió de manera significativa en respuesta a estas herramientas.

Las tres cifras proceden de autoinformes y describen percepciones antes que hechos verificados. Leídas en conjunto sugieren que el cambio en la evaluación ya ocurrió en la experiencia de los estudiantes, y que la formación en el uso de la herramienta no acompañó ese cambio.

3. El profesorado

Las encuestas del Digital Education Council, cuya oleada de 2025 recogió respuestas de 1.681 docentes de cincuenta y dos instituciones en veintiocho países, muestran que el uso docente de estas herramientas en la enseñanza pasó del 61 % en 2025 al 77 % en 2026. La adopción, por lo tanto, alcanzó también al profesorado.²

Los indicadores de preparación siguen otra trayectoria, según muestra el gráfico 2. El 83 % del profesorado declara preocupación por la capacidad de sus estudiantes para evaluar críticamente lo que estas herramientas producen. El 80 % percibe falta de claridad institucional sobre lo que está permitido. Solo el 17 % se sitúa en un nivel avanzado o experto de alfabetización en la materia, y el 40 % declara encontrarse en el inicio de ese proceso. Únicamente el 31 % participó en la elaboración de la política de su institución.

Gráfico 2. Indicadores de preparación docente y estudiantil



Fuente: Digital Education Council, oleadas de 2025 y 2026. Encuesta autoinformada de muestra autoseleccionada; los porcentajes describen a quienes respondieron.


Del lado estudiantil, el 57 % declara que sus evaluaciones vienen con orientación insuficiente sobre el uso admisible de estas herramientas, y solo el 29 % cree que sus docentes están preparados para orientarlos. La distancia entre el 77 % que usa y el 17 % que domina describe el punto donde se concentra hoy la dificultad, que dejó de ser la adopción de la herramienta para pasar a ser la capacidad de acompañarla.

²DIGITAL EDUCATION COUNCIL (2025 y 2026): encuestas a profesorado y estudiantado de educación superior. La oleada de 2025 recogió respuestas de 1.681 docentes de 52 instituciones en 28 países. Muestra autoseleccionada.

4. La política declarada y la política vigente

La difusión pública de las cifras institucionales sobre esta materia merece una advertencia. Una encuesta de las Cátedras UNESCO y de la red UNITWIN, con cuatrocientas respuestas en noventa países, se comunicó señalando que dos tercios de las instituciones contaban con orientaciones sobre inteligencia artificial. El desglose de la misma encuesta muestra que la política formalmente vigente alcanza al 19 %, mientras que el 42 % declara un marco en desarrollo y el 39 % no declara ninguno.³

Gráfico 3. Estado de la política institucional sobre inteligencia artificial



Fuente: Encuesta de las Cátedras UNESCO y la red UNITWIN, 2025, 400 respuestas en 90 países. Muestra no representativa de la educación superior mundial.

La diferencia entre ambas cifras no es un error de la encuesta, sino de su lectura. Una orientación en desarrollo no obliga a nadie, y el documento que obliga es el que permite a un profesor sostener una decisión de evaluación ante un estudiante que la discute. El gráfico 3 presenta el desglose.

El dato importa para el caso chileno. El informe que acompaña a este documento registra que dos de las once facultades de Derecho examinadas cuentan con norma propia, mientras que las restantes se rigen por instrumentos universitarios de carácter orientador. La proporción chilena no difiere sustancialmente de la que describe la encuesta internacional.

5. Consecuencia del capítulo

La adopción de estas herramientas por estudiantes y profesores ya ocurrió, con independencia de cualquier decisión institucional pendiente. Lo que sigue abierto es otra cuestión, que los capítulos siguientes examinan: si los instrumentos con que la universidad acredita el aprendizaje conservan validez en ese contexto, y qué se sabe sobre el efecto de estas herramientas en lo que los estudiantes aprenden.

³Encuesta a responsables de Cátedras UNESCO y de la red UNITWIN, 2025, con 400 respuestas en 90 países. La muestra no es representativa del conjunto de la educación superior y sobrerrepresenta a instituciones con vínculos con la organización.

V. La evaluación escrita y su valor probatorio

1. El experimento de Reading

La afirmación central de este capítulo descansa en un experimento antes que en una apreciación general sobre la tecnología. Scarfe, Watcham, Clarke y Roesch prepararon entregas generadas íntegramente por un modelo de lenguaje y las insertaron en el sistema real de exámenes de cinco módulos de Psicología de la Universidad de Reading, donde fueron corregidas a ciegas por los propios evaluadores de los cursos, que desconocían el experimento. El 94 % de esas entregas no fue detectado y obtuvo, en promedio, calificaciones superiores a las de los estudiantes reales.⁴

El diseño importa para fijar el alcance del resultado. No se trata de una encuesta sobre lo que los profesores creen poder detectar, ni de un ejercicio de laboratorio, sino de una prueba realizada dentro del procedimiento institucional de evaluación, con los correctores habituales y sin aviso previo. La conclusión que autoriza es acotada y firme: en ese sistema de evaluación, el trabajo escrito no supervisado dejó de discriminar entre quien lo produjo y quien lo encargó.

La consecuencia alcanza también al estudiante honesto. Un trabajo elaborado con asistencia razonable y declarada sigue siendo un texto correcto que el profesor no puede distinguir de otro escrito sin ayuda, de modo que la calificación deja de informar sobre la capacidad individual aunque nadie haya infringido ninguna regla. La cuestión, por lo tanto, no pertenece al ámbito de la integridad académica, sino al de la validez del instrumento.

2. Por qué la detección automática no resolvió el problema

La respuesta inicial de muchas instituciones consistió en adquirir sistemas de detección. La evidencia acumulada desaconseja esa vía por dos razones independientes.

La primera es la tasa de falsos positivos y su distribución desigual. Un estudio de Stanford de 2023 evaluó siete detectores sobre ensayos escritos por hablantes no nativos de inglés y encontró una tasa media de falsos positivos del 61,3 %.⁵ El error no se reparte al azar: recae sobre quienes escriben con sintaxis más simple y vocabulario más previsible, que es el perfil habitual del estudiante extranjero o de origen socioeconómico menos favorecido. Una institución que sanciona a partir de esa señal introduce una discriminación sistemática.

La segunda razón que desaconseja esa vía es aritmética. La Universidad Vanderbilt desactivó el detector de su proveedor en agosto de 2023 con un argumento que conviene reproducir: con setenta y cinco mil trabajos procesados en un año y una tasa de falsos positivos del 1 % declarada por el propio proveedor, unos setecientos cincuenta trabajos habrían sido

⁴SCARFE, Peter; WATCHAM, Kelly; CLARKE, Alasdair, y ROESCH, Etienne (2024): «A real-world test of artificial intelligence infiltration of a university examinations system», *PLOS ONE*. Entregas generadas por modelo de lenguaje insertadas en cinco módulos de Psicología de la University of Reading, con corrección ciega por los evaluadores del curso.


⁵LIANG, Weixin y otros (2023): estudio sobre el sesgo de los detectores de texto generado frente a hablantes no nativos de inglés. Siete detectores evaluados; tasa media de falsos positivos del 61,3 %.

señalados erróneamente. A marzo de 2026, al menos doce instituciones de primer orden, entre ellas Yale, Johns Hopkins y Northwestern, habían desactivado esas herramientas.

3. Lo que miden las cifras disciplinarias

Una investigación de prensa británica, mediante solicitudes de acceso a la información dirigidas a ciento cincuenta y cinco universidades, de las que respondieron ciento treinta y una, documentó que los casos probados de mala conducta académica con inteligencia artificial pasaron de 1,6 por cada mil estudiantes en el año 2022-2023 a 5,1 en 2023-2024, con una proyección de 7,5 para 2024-2025.⁶ En el grupo de universidades de investigación intensiva del Reino Unido, los estudiantes sancionados pasaron de unos setecientos a más de dos mil en un año.

Gráfico 4. Casos probados de mala conducta académica con inteligencia artificial por cada mil estudiantes



Fuente: Solicitudes de acceso a la información a 155 universidades del Reino Unido, con 131 respuestas. La cifra de 2024-2025 es una proyección.

El gráfico 4 presenta la serie. Su lectura exige una precisión que suele quedar fuera: la cifra mide detección, sin alcanzar la prevalencia. Una serie que se multiplica por cuatro en dos años puede describir un aumento del incumplimiento, una mejora de los mecanismos de detección o un cambio en la disposición institucional a abrir procedimientos. La distancia entre siete casos probados por cada mil estudiantes y el 94 % que declara usar la herramienta indica, en cualquier caso, que la vía disciplinaria no está resolviendo el problema que dice atender.

⁶Investigación periodística basada en solicitudes de acceso a la información dirigidas a 155 universidades del Reino Unido, con 131 respuestas. Los datos corresponden a casos probados en procedimientos disciplinarios, sin informar la prevalencia del uso.

4. La respuesta de los dos carriles

La respuesta institucional más desarrollada procede de Australia. La Universidad de Sídney formalizó en noviembre de 2024 un modelo de evaluación de dos carriles, desplegado de manera progresiva desde el primer semestre de 2025.⁷

El primer carril es supervisado y sin ayudas externas, y su función es garantizar que el estudiante posee las capacidades nucleares de su programa. La decisión sobre qué se sitúa en ese carril se adopta en el nivel del programa, fuera del alcance de cada asignatura, lo que evita que la garantía dependa del criterio individual de cada profesor. El segundo carril es abierto, admite el uso de estas herramientas con declaración y su función es desarrollar capacidades, incluida la de emplear la tecnología con juicio.

El regulador australiano fijó dos principios para orientar la reforma: preparar a los estudiantes para participar de manera ética y activa en una sociedad donde estas herramientas son ubicuas, y formar juicios fiables sobre el aprendizaje mediante enfoques múltiples, inclusivos y contextualizados. La Universidad de Bath anunció que abandonará su sistema anterior y adoptará un enfoque de dos carriles desde el curso 2026-2027.

5. Qué instrumentos conservan valor probatorio

El examen de los instrumentos de evaluación habituales, a la luz de lo anterior, permite ordenarlos según el valor probatorio que conservan.

El ensayo domiciliario y el cuestionario en línea sin supervisión conservan un valor muy bajo, porque son las tareas que el experimento de Reading demostró indistinguibles. El examen presencial supervisado conserva un valor alto, con la limitación conocida de que privilegia la reproducción de contenido sobre el juicio aplicado. La defensa oral, el desempeño observado y el trabajo asistido con proceso documentado conservan un valor muy alto, porque exigen que el estudiante responda en tiempo real por lo que presenta.

Esta ordenación tiene una consecuencia de costo que el capítulo X retoma. Los instrumentos que conservan valor probatorio consumen tiempo docente en proporción directa al número de estudiantes, mientras que los que lo perdieron eran justamente los que permitían evaluar a muchos con poco tiempo. El problema de la reforma evaluativa es, en su núcleo, un problema de asignación de horas.

⁷UNIVERSITY OF SYDNEY, política de evaluación de dos carriles, formalizada en noviembre de 2024 y desplegada desde el primer semestre de 2025. Los principios del regulador corresponden a la Tertiary Education Quality and Standards Agency de Australia.

VI. El efecto sobre el aprendizaje


1. Dos ensayos que parecen contradecirse

La pregunta sobre si estas herramientas ayudan o perjudican el aprendizaje tiene menos respuestas experimentales de las que su difusión pública sugiere. Dos ensayos aleatorizados publicados en 2025 concentran buena parte de lo que puede afirmarse, y sus resultados apuntan en direcciones opuestas.

El primero se realizó en Harvard, en el curso Physical Sciences 2, durante el otoño de 2023. Kestin, Miller, Kiales, Milbourne y Ponti asignaron a unos ciento ochenta estudiantes que alternaran semanalmente entre una clase de aprendizaje activo y un tutor basado en un modelo de lenguaje. Ese tutor incorporaba andamiajes redactados por expertos, razonamiento paso a paso y restricciones explícitas para no entregar la respuesta directa. Las ganancias de aprendizaje con el tutor duplicaron a las obtenidas con la clase de aprendizaje activo, que es a su vez el método presencial con mejor respaldo empírico.⁸

El segundo se realizó en Turquía con cerca de mil estudiantes de secundaria, en cuatro sesiones de noventa minutos. Bastani y otros compararon tres condiciones: acceso libre a un modelo de lenguaje, acceso a un tutor con restricciones y ausencia de la herramienta. El acceso libre mejoró el desempeño un 48 % mientras la herramienta estaba disponible. Al retirarla, ese mismo grupo quedó un 17 % por debajo de quienes nunca la habían tenido.⁹

Gráfico 5. Variación del desempeño con la herramienta disponible y tras retirarla



Fuente: Bastani y otros (2025), experimento de campo con cerca de mil estudiantes de secundaria en Turquía. La revista publicó una corrección el 20 de agosto de 2025.

El gráfico 5 presenta las tres condiciones. Dos advertencias acompañan a este estudio cada vez que se cita. La primera es que se realizó con estudiantes de secundaria, de modo que su traslado a la educación universitaria constituye una inferencia antes que un dato. La segunda es que la revista publicó una corrección el 20 de agosto de 2025.

2. La regla que ambos sugieren

Los dos resultados dejan de parecer contradictorios cuando se atiende a lo que cada intervención hizo. En ambos casos el modelo subyacente era del mismo tipo. Lo que cambió

⁸KESTIN, Gregory; MILLER, Kelly; KLALES, Anna; MILBOURNE, Timothy, y PONTI, Gregorio (2025): «AI tutoring outperforms in-class active learning», *Scientific Reports*. Ensayo aleatorizado en el curso Physical Sciences 2 de Harvard, otoño de 2023, con unos 180 estudiantes.

⁹BASTANI, Hamsa y otros (2025): experimento de campo en Turquía con cerca de mil estudiantes de secundaria, en cuatro sesiones de noventa minutos. La revista publicó una corrección el 20 de agosto de 2025. La población es escolar, fuera del ámbito universitario.

fue el diseño de la interacción: en Harvard el sistema estaba construido para no entregar la respuesta y conducir al estudiante por pasos; en Turquía la condición que produjo el daño fue el acceso libre, sin restricción alguna.

De ahí se sigue la afirmación mejor sostenida de este capítulo. Lo que determina si estas herramientas ayudan o perjudican el aprendizaje es el diseño pedagógico de la tarea, antes que el acceso a la tecnología. La condición intermedia del experimento turco, con un tutor restringido, confirma la regla desde el otro lado, porque no produjo el deterioro posterior que sí produjo el acceso libre.

Esta conclusión invierte la lógica de gasto que predomina en el sector. Adquirir licencias de acceso general, que es la inversión mayoritaria de las instituciones examinadas en el capítulo IX, es la intervención con menor respaldo empírico de producir aprendizaje, y el experimento turco indica que puede producir el efecto contrario. La intervención que cuenta con evidencia favorable es el rediseño de tareas y andamiajes, que consiste en trabajo docente cualificado.

3. La distancia entre el rendimiento percibido y el medido

Un segundo grupo de resultados examina si quien usa estas herramientas sabe cuánto le están ayudando. La respuesta disponible sugiere que no.

En julio de 2025, METR publicó un ensayo aleatorizado con dieciséis desarrolladores de software experimentados que completaron doscientas cuarenta y seis tareas reales en sus propios repositorios. Con asistencia de inteligencia artificial tardaron un 19 % más que sin ella. Antes del experimento habían previsto ser un 24 % más rápidos, y después de realizarlo estimaron que lo habían sido.¹⁰ La discrepancia entre la percepción y la medición es el hallazgo del estudio, por encima del signo del efecto.

El trabajo se refiere a programación, fuera por tanto de la formación jurídica, y sus propios autores lo califican hoy de documento histórico por la velocidad con que cambiaron las herramientas evaluadas. Se cita aquí por la naturaleza del hallazgo, que es independiente de la tarea: la sensación de fluidez que produce trabajar con estas herramientas no es un indicador fiable del rendimiento efectivo, y menos aún del aprendizaje.

Para el diseño de la evaluación esa observación tiene una consecuencia directa. Un estudiante que declara de buena fe haber aprendido con asistencia de inteligencia artificial no está proporcionando evidencia de haber aprendido.

4. Homogeneización y desempeño desigual

Doshi y Hauser publicaron en julio de 2024 un experimento sobre escritura de relatos breves. El acceso a ideas generadas por un modelo de lenguaje hizo que los textos fueran evaluados como más creativos y mejor escritos, con una mejora concentrada en los participantes de

¹⁰MODEL EVALUATION AND THREAT RESEARCH (2025): ensayo aleatorizado con 16 desarrolladores experimentados y 246 tareas reales, julio de 2025. Sus autores califican hoy el trabajo de documento histórico, dada la evolución posterior de las herramientas evaluadas.

menor habilidad previa. El conjunto de relatos producidos con asistencia resultó, al mismo tiempo, más parecido entre sí que el producido sin ella.¹¹

El patrón de mejora desigual reaparece en el ámbito jurídico, según examina el capítulo VIII, y constituye uno de los resultados más consistentes de esta literatura. Estas herramientas elevan el desempeño de quien parte de una base más débil y aportan poco, o restan, a quien parte de una base sólida.

La homogeneización del producto plantea una cuestión distinta y menos estudiada. Si los trabajos escritos con asistencia se parecen más entre sí, la evaluación pierde capacidad de discriminar entre estudiantes por una vía adicional a la descrita en el capítulo V, que es la reducción de la varianza en lo que recibe el corrector.

5. Lo que no se sabe

Conviene delimitar el estado de esta evidencia, porque su difusión pública ha sido más segura de lo que los estudios permiten.

La base experimental es pequeña. Los dos ensayos citados en el apartado 1 son los de mayor calidad disponibles sobre efecto en aprendizaje, y uno de ellos se realizó con población escolar. No se localizó ningún ensayo aleatorizado sobre efecto de estas herramientas en el aprendizaje jurídico realizado fuera de los Estados Unidos.

El estudio del MIT Media Lab que registró con electroencefalografía la actividad de cincuenta y cuatro participantes mientras escribían, y que informó menor conectividad cerebral en el grupo que empleaba un modelo de lenguaje, ha circulado como prueba de deterioro cognitivo. Su tamaño muestral, su duración y la distancia entre una medida de conectividad y una afirmación sobre aprendizaje no autorizan esa lectura.

La referencia más citada a favor de efectos positivos grandes fue retractada. El metaanálisis de Wang y Fan, publicado en *Humanities and Social Sciences Communications*, se retiró el 22 de abril de 2026 tras acumular doscientas sesenta y seis citas y cerca de cuatrocientas ochenta y seis mil visualizaciones, por agrupar estudios demasiado heterogéneos para combinarse. Durante once meses sostuvo políticas institucionales y presentaciones de autoridades universitarias.

Falta, por último, lo que resultaría más útil para una escuela de Derecho: estudios de seguimiento que midan qué ocurre con la capacidad del estudiante meses después de la intervención, en lugar del momento mismo de realizarla. El experimento turco es el único de los citados que mide algo después de retirar la herramienta, y lo hace en el plazo inmediato.

¹¹DOSHI, Anil, y HAUSER, Oliver (2024): «Generative AI enhances individual creativity but reduces the collective diversity of novel content», *Science Advances*, julio de 2024.

VII. Competencias, profesorado y equidad

1. Qué capacidades quedan y cuáles se desplazan

Los capítulos anteriores describen un desacoplamiento entre el producto que el estudiante entrega y la capacidad que ese producto acreditaba. Queda por examinar qué capacidades resultan afectadas y en qué sentido, porque de ello depende el contenido de la lista que el capítulo X propone elaborar.

La distinción útil no pasa entre capacidades que sobreviven y capacidades que desaparecen, sino entre operaciones que la herramienta ejecuta con buen rendimiento y operaciones donde su rendimiento es pobre o nulo. Entre las primeras se cuentan la reproducción ordenada de contenido conocido, la síntesis de textos extensos, la producción de un primer borrador y la traducción entre registros. Entre las segundas se cuentan la verificación de que una fuente existe y dice lo que se le atribuye, la valoración del peso relativo de argumentos en un caso concreto, la decisión sobre qué hechos son jurídicamente relevantes y la respuesta en tiempo real ante una objeción.

Esa distribución tiene una consecuencia que la literatura sobre competencias formula con más seguridad de la que la evidencia autoriza, y que aquí se enuncia con reservas. Las operaciones del segundo grupo suponen las del primero: no se valora el peso de un argumento que no se comprende, ni se verifica una cita cuyo contenido no se sabe leer. Si la formación deja de ejercitar el primer grupo por considerarlo automatizable, es razonable esperar que el segundo se resienta, aunque ningún estudio de los examinados lo haya medido.

2. La distancia entre el rendimiento y el criterio

Los datos de uso publicados por uno de los proveedores muestran que, entre estudiantes universitarios, cerca del 47 % de las interacciones son directas, y que las categorías cognitivas más frecuentes son crear, con un 39,8 %, y analizar, con un 30,2 %, mientras que recordar resulta marginal.¹²

La cifra procede del propio proveedor de la herramienta y describe la conducta de quienes la usan, sin informar sobre el resultado de esa conducta. Se cita aquí porque documenta que el uso predominante no consiste en consultar datos, sino en encargar la producción de contenido y su análisis, que son las operaciones que la evaluación escrita pretendía medir.

El hallazgo de METR descrito en el capítulo VI adquiere aquí su relevancia formativa. Si quien emplea estas herramientas no percibe con exactitud cuánto lo están ayudando, tampoco puede regular por sí solo cuándo conviene emplearlas y cuándo no. La capacidad de decidir en qué momento delegar una tarea y en cuál ejecutarla personalmente es, por lo tanto, una competencia que el estudiante no adquiere por el solo uso de la herramienta, y que ninguna de las instituciones examinadas enseña de manera explícita.

¹²Datos de uso publicados por un proveedor de herramientas de inteligencia artificial generativa sobre interacciones de estudiantes universitarios. La fuente es el propio proveedor y describe conducta declarada por el sistema, sin informar sobre resultados de aprendizaje.

3. El profesorado como condición de todo lo anterior

Las cifras del capítulo IV describen un profesorado que adoptó la herramienta sin haber recibido formación para orientarla. El 77 % la emplea en su enseñanza, el 17 % se sitúa en un nivel avanzado de alfabetización, el 40 % declara encontrarse en el inicio de ese proceso y solo el 31 % participó en la elaboración de la política de su institución.

De esas cuatro cifras la más relevante para una escuela de Derecho es la última. Una política sobre uso de inteligencia artificial en evaluación que se dicta sin participación del cuerpo académico produce un documento que los profesores no aplican, porque no reconocen en él las decisiones que enfrentan en sus propios cursos. La medida del capítulo X sobre las capacidades exigidas sin asistencia está diseñada para evitar ese resultado, ya que su elaboración corresponde al cuerpo académico antes que a una unidad administrativa.

La cuestión del tiempo docente merece un examen aparte, porque suele presentarse como argumento a favor de la adopción. Un trabajo sobre corrección híbrida entre instructor e inteligencia artificial en cursos de hidráulica informa una reducción del tiempo de corrección del 88 %, de cincuenta a seis minutos por informe.¹³ Una revisión integrativa publicada en 2025 califica, sin embargo, de metodológicamente deficiente el conjunto de la evidencia sobre ahorro de tiempo docente, por el predominio de estudios de corto plazo y evaluaciones subjetivas.

La conclusión que este informe sostiene sobre ese punto es de cautela. El ahorro de tiempo en corrección, aunque se confirme, se produce en el instrumento cuyo valor probatorio disminuyó, y no en los que lo conservan. Automatizar la corrección del ensayo domiciliario reduce el costo de un procedimiento que el capítulo V describe como poco informativo.

4. La brecha de aprendizaje asistido

Un conjunto de resultados examina si el acceso a estas herramientas se distribuye de manera uniforme, y la respuesta disponible indica que no.

Un documento de trabajo de la Escuela de Negocios de Harvard que agrega dieciocho estudios con ciento cuarenta y tres mil ocho personas en veinticinco países estima que las mujeres tienen un 22 % menos de probabilidades de emplear inteligencia artificial generativa que los hombres.¹⁴ El trabajo no ha sido revisado por pares y su resultado procede de la agregación de estudios heterogéneos, de modo que la cifra debe tomarse como orden de magnitud.

Las condiciones materiales agregan una segunda desigualdad. En los países de ingreso bajo solo el 17 % de los establecimientos educativos dispone de acceso a internet, frente al 90 % en los de ingreso alto. El rendimiento de los modelos, además, es inferior fuera del inglés y desigual entre variedades del español y del portugués, lo que afecta de manera directa a la formación jurídica en lengua castellana.

¹³Estudio sobre corrección híbrida entre instructor e inteligencia artificial en cursos de hidráulica, con reducción informada del tiempo de corrección de 50 a 6 minutos por informe. La revisión integrativa que cuestiona la calidad de esta evidencia se publicó en *Frontiers in Education* en 2025.

¹⁴OTIS, Nicholas; DELECOURT, Solène; CRANNEY, Katelyn, y KONING, Rembrand: documento de trabajo de la Harvard Business School que agrega 18 estudios con 143.008 personas en 25 países. No revisado por pares.

En sentido contrario operan dos efectos documentados. El primero es el patrón de mejora desigual descrito en los capítulos VI y VIII, por el cual estas herramientas elevan el desempeño de quien parte de una base más débil. El segundo es la mejora de accesibilidad para estudiantes con dislexia, déficit atencional o discapacidad auditiva, que la literatura registra de manera consistente.

La combinación de ambos conjuntos de efectos produce una situación que conviene formular sin simplificar. Estas herramientas reducen algunas desigualdades de desempeño y amplían otras de acceso, y su efecto neto sobre la equidad depende de decisiones institucionales concretas antes que de la tecnología. Una institución que provee acceso uniforme y formación en su uso opera sobre el segundo conjunto de efectos; una que deja el acceso a la iniciativa individual traslada la desigualdad de origen al resultado académico.

5. Consecuencia del capítulo

Tres conclusiones de este capítulo se incorporan a las decisiones del capítulo X.

La primera es que la lista de capacidades exigidas sin asistencia debe elaborarla el cuerpo académico, porque una política dictada sin su participación no se aplica en los cursos.

La segunda es que el ahorro de tiempo docente que se atribuye a estas herramientas se produce en los instrumentos de evaluación que perdieron valor probatorio, de modo que no compensa el costo de los que lo conservan.

La tercera es que la decisión sobre cuándo delegar una tarea y cuándo ejecutarla personalmente constituye una competencia que el estudiante no adquiere por el solo uso de la herramienta, y que ninguna institución examinada enseña de manera explícita.

VIII. El Derecho como caso crítico

1. Por qué el Derecho está más expuesto

Las consecuencias descritas en los capítulos anteriores alcanzan a toda la enseñanza universitaria. El Derecho las recibe, sin embargo, de manera más directa que otras disciplinas, por dos rasgos que pertenecen al oficio antes que a la enseñanza.

El primero es la verificación de fuentes. Comprobar que una norma existe, que está vigente, que dice lo que se afirma y que su interpretación jurisprudencial es la que se invoca no es una formalidad accesorio del trabajo jurídico, sino una parte de él. Ese control se realizaba de manera incidental mientras el estudiante o el abogado buscaba personalmente el material. Cuando la búsqueda se encarga a un sistema que produce texto plausible, el control deja de ocurrir por sí solo y pasa a requerir un paso deliberado y separado.

El segundo rasgo es la responsabilidad personal por lo firmado. El abogado responde ante el tribunal, ante su cliente y ante su colegio profesional por el contenido de lo que suscribe, y esa responsabilidad no se transfiere a la herramienta empleada. Un error que en otra disciplina produce una mala calificación, en Derecho produce una resolución adversa, una sanción procesal o un procedimiento disciplinario.


De ambos rasgos se sigue que la formación jurídica tiene un interés propio, y más urgente que el de otras carreras, en establecer qué debe saber hacer un titulado sin asistencia.

2. La fiabilidad medida de las herramientas jurídicas

La afirmación de que estos sistemas producen contenido inventado suele hacerse en términos generales. Existe, sin embargo, una medición específica para herramientas jurídicas comerciales, realizada por un equipo de Stanford y publicada en el *Journal of Empirical Legal Studies*.

Magesh, Surani, Dahl, Suzgun, Manning y Ho evaluaron doscientas dos consultas jurídicas preregistradas sobre herramientas comerciales de investigación jurídica que declaraban estar libres de este problema. Lexis+ AI entregó contenido inventado en el 17 % de las consultas y respondió correctamente el 65 %. Westlaw AI-Assisted Research entregó contenido inventado en el 33 % y respondió correctamente el 42 %. Un modelo general sin recuperación jurídica especializada alcanzó el 43 % de respuestas con contenido inventado.¹⁵

¹⁵MAGESH, Varun; SURANI, Faiz; DAHL, Matthew; SUZGUN, Mirac; MANNING, Christopher, y HO, Daniel (2025): «Hallucination-free? Assessing the reliability of leading AI legal research tools», *Journal of Empirical Legal Studies*. Evaluación de 202 consultas jurídicas preregistradas. Un trabajo anterior del mismo equipo, publicado en el *Journal of Legal Analysis*, estimó tasas de entre el 58 % y el 88 % en modelos generales sobre más de 800.000 consultas verificables.

Gráfico 6. Respuestas con contenido inventado en herramientas de investigación jurídica


Fuente: Magesh y otros, *Journal of Empirical Legal Studies*. 202 consultas jurídicas preregistradas sobre herramientas comerciales.

El gráfico 6 presenta las tres cifras, que admiten dos observaciones. La primera es que las herramientas especializadas, construidas sobre bases de datos jurídicas propias, reducen el problema sin eliminarlo: una de cada tres consultas a la segunda de ellas devolvió contenido inventado. La segunda es que los autores concluyeron que las afirmaciones de los proveedores sobre herramientas libres de este defecto estaban sobredimensionadas.

De la cifra se sigue una consecuencia formativa. Una tasa del 17 % es suficientemente baja para que el usuario adquiera confianza en la herramienta y suficientemente alta para que el error llegue a un escrito. Es la combinación que más exige de la verificación, porque el fallo no es evidente ni frecuente, sino ocasional y verosímil.

3. Los tribunales ante las citas inventadas

La consecuencia práctica de lo anterior puede observarse en un registro público. Damien Charlotin mantiene una base de datos que recoge exclusivamente resoluciones en que un tribunal constató el uso de contenido jurídico inventado en una presentación. El registro superaba los mil doscientos casos a comienzos de 2026, alcanzaba mil seiscientos sesenta y ocho en julio del mismo año y registraba mil novecientos ochenta y uno el 28 de agosto de 2026.¹⁶

Gráfico 7. Resoluciones judiciales en que un tribunal constató citas inventadas, registro acumulado

Fuente: Base de datos de Damien Charlotin. Solo incluye casos en que el tribunal dejó constancia expresa; el subregistro es previsible.

¹⁶CHARLOTIN, Damien: base de datos de resoluciones judiciales con contenido jurídico inventado. El registro incorpora únicamente casos en que el tribunal dejó constancia expresa del hecho.

El gráfico 7 presenta la serie acumulada. Su lectura exige la misma cautela que la de las cifras disciplinarias del capítulo V, y por la misma razón: el registro solo recoge los casos en que un tribunal advirtió el problema y dejó constancia de él, de modo que la cifra describe detección judicial antes que frecuencia real.

Lo relevante para una escuela de Derecho no es la magnitud de la serie, sino su naturaleza. Cada uno de esos casos corresponde a un abogado titulado que presentó ante un tribunal una cita que no existía, lo que indica que la operación de verificación, que la formación jurídica presume adquirida, no se está ejecutando de manera fiable en el ejercicio profesional.

4. El efecto sobre el aprendizaje jurídico

La evidencia experimental sobre efecto en estudiantes de Derecho es escasa y procede, en su mayor parte, de un mismo equipo de investigación estadounidense.

El trabajo de Choi y Schwarcz, publicado en el *Journal of Legal Education*, comparó el desempeño de cuarenta y ocho estudiantes de Derecho con y sin acceso a un modelo de lenguaje. En el conjunto de la muestra, el acceso mejoró la calidad del análisis jurídico de manera ligera e inconsistente, y aumentó la velocidad de manera amplia y consistente. El hallazgo más citado del estudio es, sin embargo, la distribución de ese efecto: los estudiantes con peor rendimiento previo mejoraron alrededor de cuarenta y cinco puntos percentiles, mientras que los de mejor rendimiento previo empeoraron sus calificaciones.¹⁷

Un trabajo posterior del mismo equipo, con ciento treinta y siete estudiantes de dos facultades y diseño aleatorizado, encontró aumentos de productividad de entre el 34 % y el 140 % en cinco de seis tareas, con mejoras moderadas de calidad global y un efecto negativo en la redacción de un acuerdo de confidencialidad.¹⁸

El patrón coincide con el descrito en el capítulo VI para otras disciplinas. Estas herramientas elevan el desempeño de quien parte de una base más débil y aportan poco, o restan, a quien ya domina la tarea. Para una escuela de Derecho el dato admite dos lecturas que deben mantenerse separadas. En términos de producto, la herramienta reduce la dispersión entre estudiantes, lo que mejora el trabajo del grupo menos preparado. En términos de aprendizaje, ese mismo efecto elimina la señal que permitía al profesor identificar a quién debía atender.

Un tercer trabajo del mismo grupo, con cerca de cien estudiantes y cuatro tareas secuenciales, es el único que mide aprendizaje en lugar de desempeño. Encontró que la exposición previa a la herramienta no deterioró la comprensión posterior. Se trata de un documento de trabajo no revisado por pares, y su resultado, que apunta en dirección tranquilizadora, debe tomarse con esa reserva.

5. Lo que la evidencia jurídica no cubre

Tres vacíos delimitan el alcance de lo anterior y quedan aquí consignados.

¹⁷CHOI, Jonathan, y SCHWARCZ, Daniel (2023): «AI assistance in legal analysis: an empirical study», *Journal of Legal Education*. Estudio intrasujeto no aleatorizado con 48 estudiantes de Derecho.

¹⁸SCHWARCZ, Daniel; MANNING, Sam; PRESCOTT, Patrick; BARRY, Shannon; CLEVELAND, Charlotte, y RICH, Joe (2026): ensayo controlado aleatorizado con 137 estudiantes de dos facultades de Derecho, publicado en el *Journal of Law & Empirical Analysis*.

El primer vacío es de orden geográfico. Los estudios experimentales sobre inteligencia artificial y educación jurídica se realizaron todos en los Estados Unidos, y tres de ellos por el mismo equipo. No se localizó ningún ensayo controlado aleatorizado sobre esta materia en Europa, Australia ni América Latina.

El segundo vacío es de sistema jurídico. Las tareas evaluadas corresponden a la práctica del *common law*, donde la investigación de precedentes ocupa un lugar distinto del que tiene en un sistema de derecho codificado. El traslado de esos resultados a la formación jurídica chilena es una inferencia razonable antes que un dato.

El tercer vacío es de plazo de observación. Ninguno de los estudios citados mide qué ocurre con la capacidad del estudiante al término de su carrera, ni en el ejercicio profesional posterior. La pregunta que más interesa a una escuela de Derecho es la que la evidencia disponible no responde.

Existe, con todo, un antecedente chileno que corresponde señalar. En 2024, cuatro académicos de la Facultad de Derecho de la Pontificia Universidad Católica de Valparaíso publicaron los resultados de cuatro casos de estudio sobre el uso de asistentes virtuales en la enseñanza del Derecho, realizados entre 2019 y 2022, con grupo experimental, grupo de control y comparación entre una prueba inicial y una final.¹⁹ Los tres primeros casos registraron mejoras en el grupo experimental, y el tercero informó diferencias estadísticamente significativas. El cuarto, realizado en modalidad presencial con acompañamiento docente en la sala, mostró resultados mixtos que los autores atribuyen a esa circunstancia.

El valor probatorio de ese trabajo para la pregunta de este informe es acotado por tres razones. Las muestras son pequeñas, de entre dieciséis y cincuenta y seis estudiantes. Los casos difieren entre sí en carrera, contenido, herramienta y modalidad, de modo que la comparación entre ellos es descriptiva. Y las herramientas evaluadas son asistentes conversacionales anteriores a la inteligencia artificial generativa, cuyos resultados no se trasladan sin más a los modelos de lenguaje actuales. Con esas reservas, es el único estudio con grupo de control sobre enseñanza del Derecho asistida producido en alguna de las once facultades chilenas examinadas en el informe que acompaña a este documento.

6. La escritura jurídica y los instrumentos que resisten

La escritura jurídica ocupa en la formación del abogado un lugar que excede al de una destreza de expresión. Redactar un informe obliga a decidir qué hechos son relevantes, qué norma los rige, qué objeciones cabe anticipar y en qué orden ha de presentarse el argumento. Esas decisiones se toman durante la redacción, de modo que el texto es a la vez el producto y el registro del razonamiento que lo produjo.

¹⁹FAÚNDEZ-UGALDE, Antonio; MELLADO-SILVA, Rafael; ALDUNATE-LIZANA, Eduardo, y BENFELD ESCOBAR, Johann (2024): «La enseñanza-aprendizaje del derecho a través de asistentes virtuales: principales hallazgos en estudiantes universitarios de pregrado», *Revista Pedagogía Universitaria y Didáctica del Derecho*, vol. 11, n.º 1, pp. 31-48. Disponible en: <https://doi.org/10.5354/0719-5885.2024.69639>. El trabajo declara financiamiento del proyecto Fondecyt de Iniciación n.º 11200596 y del Núcleo de Derecho, Inteligencia Artificial y Tecnología de la Escuela. El autor de este informe figura entre los ayudantes de investigación agradecidos en el artículo, circunstancia que se declara aquí.

Cuando la producción del texto se delega, esa correspondencia se rompe. El estudiante que revisa y corrige un borrador generado realiza una operación distinta de la de componerlo, y probablemente más cercana a la que realizará como profesional. La operación de revisar, con todo, presupone el criterio que la composición enseñaba a formar, lo que plantea a la escuela de Derecho una cuestión de secuencia antes que de prohibición: en qué momento de la carrera el estudiante ha adquirido el criterio que le permite revisar con provecho.

La ordenación de instrumentos del capítulo V se traduce, en el ámbito jurídico, en términos concretos. El informe domiciliario y el comentario de jurisprudencia entregado fuera del aula conservan hoy escaso valor probatorio. El examen presencial escrito lo conserva, con la limitación de que privilegia la memoria de contenido normativo sobre el juicio aplicado. La defensa oral de un trabajo, el alegato y la observación del desempeño en clínica jurídica conservan el valor más alto, porque exigen al estudiante responder en tiempo real por lo que sostiene y admiten repreguntas.

Existe literatura que sostiene que la competencia oral es lo que estas herramientas no pueden sustituir en la formación jurídica, y que su desplazamiento histórico por la evaluación escrita respondió a razones de conveniencia administrativa antes que pedagógicas. La observación es pertinente y su respaldo empírico, escaso; se recoge aquí como argumento antes que como dato.

7. El acceso a la profesión

Dos hechos del entorno profesional afectan a la formación jurídica y quedan registrados aquí, aunque su alcance chileno sea indirecto.

El primero se refiere a los exámenes de acceso. La afirmación, muy difundida en 2023, de que un modelo de lenguaje había aprobado el examen de acceso a la abogacía estadounidense en el percentil noventa fue corregida por un reanálisis publicado en *Artificial Intelligence and Law*, que mostró que ese percentil dependía de una población de referencia inadecuada.²⁰ El episodio ilustra la velocidad con que una cifra llamativa se incorpora al debate institucional sin su verificación.

El propio examen se encuentra en proceso de cambio. El nuevo instrumento estadounidense debutó en julio de 2026 en un número limitado de jurisdicciones, reduce el número de materias, desplaza el peso hacia la aplicación de conceptos en escenarios realistas y hacia destrezas fundamentales, entre ellas la redacción jurídica, y se rinde en los computadores de los examinandos en sedes designadas. El organismo responsable prevé entre cuatro y cinco años para su implantación completa.²¹

El segundo hecho se refiere al mercado de entrada. En el mercado jurídico estadounidense la contratación total de asociados cayó un 5 % en 2025, solo el 38 % de las contrataciones procedió directamente de la promoción egresada y la contratación lateral superó a la de

²⁰MARTÍNEZ, Eric (2024): reanálisis del desempeño de GPT-4 en el examen de acceso a la abogacía estadounidense, *Artificial Intelligence and Law*. El trabajo muestra que el percentil declarado dependía de una población de referencia inadecuada.

²¹NATIONAL CONFERENCE OF BAR EXAMINERS: nuevo examen de acceso, con debut en julio de 2026 en un número limitado de jurisdicciones, entre las primeras Maryland, Missouri y Oregón. La mayoría de las jurisdicciones transitará hacia él entre julio de 2026 y julio de 2028.

entrada.²² Las tareas que tradicionalmente formaban al abogado en sus primeros años, que consistían en buscar, resumir y redactar borradores bajo supervisión, son las que estas herramientas ejecutan con mayor rendimiento.

De ahí se sigue una consecuencia para la universidad que no depende de ninguna proyección sobre el empleo. Si el primer tramo de formación práctica que el ejercicio profesional proporcionaba se reduce, la parte de esa formación que la escuela de Derecho debe asumir aumenta. El informe no localizó ninguna institución que haya rediseñado su currículo con ese propósito explícito.

8. Qué están haciendo las facultades de Derecho

El panorama internacional de respuestas en el ámbito jurídico presenta un rasgo común: casi todas las iniciativas consisten en añadir contenido sobre inteligencia artificial, y muy pocas en modificar cómo se evalúa.

Case Western Reserve estableció en 2025 un programa de certificación obligatorio para todos los estudiantes de primer año, presentado como el primero de su tipo en una facultad de Derecho estadounidense, y en 2026 exigió además a esa cohorte desarrollar herramientas de tecnología jurídica con programación asistida. La Facultad William S. Boyd de la Universidad de Nevada en Las Vegas incorporó desde el otoño de 2026 una asignatura obligatoria de primer año sobre uso responsable de estas herramientas. La Facultad de Derecho de la Universidad de Chicago implantó desde comienzos de 2026 módulos obligatorios para todo primer año en su primer trimestre y pilota para el curso 2026-2027 una asignatura de investigación y escritura jurídica que toma la escritura sin asistencia como base y superpone el uso de la herramienta para investigación, revisión, iteración de borradores y preparación del alegato oral.²³

Esa última iniciativa es la única del conjunto que organiza la enseñanza en dos capas explícitas, con la escritura sin asistencia como base evaluable. Ninguna de las facultades examinadas documentó un rediseño evaluativo comparable al modelo australiano de dos carriles descrito en el capítulo V, y ningún currículo examinado diferencia la enseñanza del uso de estas herramientas por nivel de competencia del estudiante.

Los datos agregados confirman la distancia entre oferta y práctica. Según información de la American Bar Association correspondiente a 2024, el 55 % de los programas de Derecho ofrecía cursos especializados sobre inteligencia artificial, mientras que solo alrededor del 5 % del profesorado de Derecho la enseñaba en cursos independientes.

9. El panorama iberoamericano

En Iberoamérica la actividad es considerable y su articulación institucional, escasa.

²²Datos del mercado jurídico estadounidense correspondientes a 2025. La contratación de asociados en grandes despachos se mantuvo plana pese al crecimiento de ingresos del sector.

²³Case Western Reserve University School of Law (2025 y 2026); University of Nevada Las Vegas, William S. Boyd School of Law (otoño de 2026); University of Chicago Law School (módulos obligatorios desde comienzos de 2026 y piloto para el curso 2026-2027). El dato agregado procede del registro de la American Bar Association correspondiente a 2024.

La convocatoria «¡IA Presente!» del Banco Interamericano de Desarrollo, junto a Ceibal de Uruguay, identificó ciento noventa y tres iniciativas de inteligencia artificial educativa activas en veintidós países de América Latina y el Caribe. Ceibal creó además un laboratorio regional de inteligencia artificial para la educación junto al Banco Mundial, el propio Banco Interamericano y el centro de investigación canadiense correspondiente. La tercera edición del Índice Latinoamericano de Inteligencia Artificial, presentada por la CEPAL y el centro nacional chileno de la materia, evalúa a diecinueve países sobre más de cien subindicadores.²⁴

En el ámbito específicamente jurídico, la Facultad de Derecho de la Universidad de Valparaíso creó un laboratorio de innovación docente, Derecho, ética y tecnologías, con el propósito declarado de observar críticamente la transformación de las profesiones jurídicas y de la formación universitaria. La Pontificia Universidad Católica de Chile creó una mención en inteligencia artificial y tecnología en su magíster en Derecho. La Universidad Autónoma de Chile desarrolla un proyecto de inteligencia artificial y Derecho desde su centro de regulación y consumo, con un módulo Jean Monnet sobre inteligencia artificial y derecho privado europeo y una microcredencial internacional que partió con más de ochenta estudiantes.

En el plano nacional, el programa «Futuros Docentes en IA», impulsado desde el Ministerio de Ciencia, realizó un piloto en 2025 con cuatro universidades y cerca de doscientos futuros docentes, e inició su escalamiento desde marzo de 2026 con nueve universidades del Consejo de Rectores. MetaRed TIC Chile definió un plan de trabajo para 2025 y 2026 con la inteligencia artificial como eje.

Esta investigación no localizó en Chile un rediseño evaluativo institucional comparable al australiano, ni una modificación formal de perfiles de egreso derivada de la irrupción de estas herramientas. El contraste entre la abundancia de iniciativas y la ausencia de cambios en la evaluación y en el perfil de egreso es el rasgo que mejor describe la situación regional.

²⁴Convocatoria «¡IA Presente!» del Banco Interamericano de Desarrollo con Ceibal, implementada por Socialab, con 193 iniciativas identificadas en 22 países. Índice Latinoamericano de Inteligencia Artificial, tercera edición, CEPAL y CENIA, con 19 países evaluados sobre más de 100 subindicadores en tres dimensiones.

IX. Respuestas institucionales y sus límites

1. Cuatro modelos de gobernanza

Las universidades que han adoptado alguna posición sobre esta materia se reparten entre cuatro modelos, que el informe distingue por el tipo de decisión que cada uno supone.

El primero consiste en licenciar, es decir, contratar el acceso institucional a herramientas comerciales y ponerlo a disposición de estudiantes y profesores. Es el modelo mayoritario y el de implantación más rápida, porque la decisión es de adquisición y deja intacto el procedimiento académico.

El segundo consiste en construir un sistema propio. Requiere capacidad técnica y presupuesto sostenido, y permite fijar restricciones pedagógicas que las herramientas comerciales no ofrecen. El Tecnológico de Monterrey lanzó en septiembre de 2023 el primer modelo generativo propio de una universidad latinoamericana y declaró en 2025 más de catorce mil usuarios.²⁵

El tercero consiste en federar, esto es, coordinar decisiones entre instituciones mediante redes o consorcios, lo que reduce el costo individual a cambio de ceder parte de la autonomía de diseño.

El cuarto consiste en no adoptar decisión alguna en el nivel institucional y dejar la materia al criterio de cada unidad o de cada profesor. Es la situación de la mayoría de las facultades chilenas de Derecho, según registra el informe que acompaña a este documento.

2. Un contraejemplo de escala

El caso de mayor escala examinado permite observar qué produce el primer modelo cuando se adopta sin acompañamiento.

La Universidad Estatal de California desplegó una herramienta comercial de inteligencia artificial generativa para más de cuatrocientos setenta mil estudiantes en veintitrés campus, y renovó el contrato en mayo de 2026 por trece millones de dólares anuales. Su propia encuesta interna, con más de noventa y cuatro mil respuestas, encontró que el 52 % del profesorado percibe un efecto negativo sobre su docencia y que el 67 % de los estudiantes considera que sus profesores no les enseñan a usar la herramienta de manera eficaz.²⁶

El caso no demuestra que licenciar sea un error. Muestra que licenciar sin rediseño evaluativo, sin formación docente obligatoria y sin participación del profesorado en la decisión adquiere el nivel de transformación más superficial al precio del más profundo. El dato del capítulo VI explica por qué: el acceso a la herramienta, por sí solo, es la intervención con menor respaldo empírico de producir aprendizaje.

²⁵TECNOLÓGICO DE MONTERREY: herramienta generativa propia lanzada el 28 de septiembre de 2023, presentada como la primera de una universidad latinoamericana. Las cifras de usuarios y de ganancias de aprendizaje proceden de la comunicación institucional de 2025, sin estudio independiente publicado.

²⁶CALIFORNIA STATE UNIVERSITY: despliegue institucional para más de 470.000 estudiantes en 23 campus; renovación del contrato en mayo de 2026 por trece millones de dólares anuales. Las cifras de percepción proceden de su encuesta interna, con más de 94.000 respuestas.

3. Tres casos de contraste

Tres instituciones ilustran decisiones de otro tipo, y se describen aquí con brevedad porque son las que aparecen con mayor frecuencia en el debate institucional.

La Universidad Estatal de Ohio incorporó la competencia en inteligencia artificial como requisito transversal de egreso para todos sus programas. Es la modificación de perfil de egreso más amplia localizada, y su ejecución está en curso, de modo que no existen todavía resultados publicados.

La Universidad de Sídney adoptó el modelo de evaluación de dos carriles descrito en el capítulo V. Es el único caso del conjunto examinado que actúa sobre la evaluación antes que sobre el contenido, y el que este informe considera más pertinente para una escuela de Derecho.

El Tecnológico de Monterrey construyó una herramienta propia y declaró en 2025 ganancias de aprendizaje de entre veinte y treinta puntos con impacto en más de diez mil estudiantes. La cifra procede de la comunicación institucional, sin estudio independiente publicado que la respalde, circunstancia que el lector debe considerar al citarla.

4. Enseñar sobre la inteligencia artificial, con ella o para trabajar con ella

El examen de las iniciativas curriculares permite distinguir tres modelos, y su distribución es desigual.

El primero consiste en enseñar sobre la inteligencia artificial, esto es, añadir contenido nuevo, habitualmente obligatorio, sobre qué es la tecnología, cómo funciona y qué problemas jurídicos plantea. Es el modelo dominante: de los ocho casos de mayor profundidad curricular del mapa internacional, siete corresponden a alguna de sus variantes.


El segundo consiste en enseñar con la inteligencia artificial, es decir, modificar el modo en que se enseña y se evalúa el contenido existente. Un solo caso del mapa, el de la Universidad de Sídney, corresponde a este modelo, y lo hace por la vía de la evaluación.

El tercero consiste en enseñar para trabajar en entornos donde la tecnología ya está incorporada, lo que supondría reconstruir dentro de la formación las operaciones profesionales que el mercado deja de proveer. El informe no localizó ninguna institución que haya rediseñado su currículo con ese propósito explícito.

La distribución de los tres modelos admite una lectura directa. Añadir contenido es la respuesta de menor costo institucional, porque no obliga a revisar la evaluación ni a redistribuir horas docentes. Es también la que menos relación guarda con el problema descrito en el capítulo V.

5. La profundidad del cambio

El informe clasificó treinta instituciones de diez países según la profundidad de su respuesta, en una escala de seis niveles que va desde la ausencia de iniciativas hasta el cambio coordinado de currículo, evaluación, docencia, competencias, infraestructura y gobernanza.

Gráfico 8. Treinta instituciones según la profundidad del cambio documentado

Fuente: Elaboración del informe sobre 30 instituciones de 10 países. La muestra se escogió por documentar iniciativas, de modo que sobrerrepresenta a las instituciones más activas.

El gráfico 8 presenta la distribución de las treinta instituciones, y ninguna de ellas alcanza el nivel superior de la escala. Once se sitúan en el nivel de integración, nueve en el de política y alfabetización, ocho en el de cambio curricular y dos en el de simple despliegue de herramienta.

Tres observaciones se siguen de esa distribución, y las tres importan para calibrar cualquier decisión propia.

La primera es que ninguna institución alcanza la transformación sistémica, y ello en una muestra escogida por documentar iniciativas. La distancia entre el discurso público sobre esta materia y lo que las instituciones acreditan es considerable, y opera en ambas direcciones: nadie va tan adelantado como el discurso sugiere.

La segunda es que el tamaño del despliegue no anticipa la profundidad del cambio. La institución con más usuarios del mundo se sitúa en el nivel de política y alfabetización, mientras que la que dispone de la mejor evidencia de resultados actuó sobre dos cursos.

La tercera es que no existe evidencia de que los despliegues masivos mejoren el aprendizaje. Después de cuatro años y de compromisos presupuestarios de gran magnitud, esta investigación no localizó un solo estudio independiente que lo demuestre en educación superior. Toda la evidencia sólida disponible procede de intervenciones pequeñas y bien evaluadas.

Esta clasificación requiere una advertencia final. La muestra no es representativa, porque se construyó a partir de instituciones que publican lo que hacen, de modo que sobrerrepresenta a las más activas. El sesgo opera al alza, lo que refuerza la primera de las tres observaciones anteriores.

X. Consecuencias para una escuela de Derecho

1. Advertencia previa sobre el alcance de este capítulo

Los capítulos anteriores se limitan a describir evidencia. Este deriva de ella decisiones posibles, operación que introduce juicios que la evidencia no determina por completo. Las cinco medidas que siguen se presentan con esa distinción a la vista: en cada una se indica qué parte se apoya en un resultado medido y qué parte constituye una opción razonable entre otras.

Ninguna de las cinco requiere adquirir tecnología. Cuatro son documentales o de criterio, y la quinta es presupuestaria.

2. Las cinco medidas

Tabla 1. Cinco medidas ordenadas por costo de implementación

Medida	En qué consiste	Costo	Plazo
Establecer las capacidades exigidas sin asistencia	La Escuela responde por escrito qué debe saber hacer un titulado por sí solo. De esa lista se deriva el resto de las decisiones	nulo	un semestre
Declarar dos carriles de evaluación	Separar la evaluación que garantiza, supervisada y sobre lo nuclear, de la que desarrolla, abierta y con uso declarado, con la decisión adoptada a nivel de programa	documental	un año
Dejar de invertir en detección automática	Redirigir a diseño de tareas los recursos destinados a herramientas cuya tasa de error las hace inutilizables como fundamento de una sanción	negativo	inmediato
Evaluar la verificación de fuentes como competencia	Incorporar a la rúbrica la comprobación de que una fuente existe, dice lo que se afirma y sigue vigente, como paso separado y calificable	bajo	un año
Presupuestar horas de evaluación oral y diseño de tareas	Asignar horas docentes específicas a defensa oral, observación de desempeño y rediseño de tareas	alto	dos a tres años

Fuente: Elaboración propia a partir de la evidencia examinada en los capítulos IV a VIII.

2.1. Establecer las capacidades exigidas sin asistencia

La primera medida consiste en que la Escuela responda por escrito a una pregunta concreta: qué debe saber hacer un licenciado en Derecho sin asistencia de ninguna herramienta. La lista debe ser corta, explícita y defendible ante un colega que la discuta.

Su fundamento es que todas las decisiones posteriores dependen de ella. No es posible determinar qué se evalúa en condiciones supervisadas sin haber establecido antes qué se garantiza, ni diseñar una tarea sin saber qué capacidad pretende desarrollar. El informe no localizó ninguna institución, chilena o extranjera, que haya elaborado esa lista para la formación jurídica.

El costo es nulo y el plazo, de un semestre de trabajo del cuerpo académico. La parte que la evidencia sostiene es la necesidad de la lista; su contenido concreto es una decisión de la Escuela.

2.2. Declarar dos carriles de evaluación

La segunda medida consiste en adoptar la distinción descrita en el capítulo V entre una evaluación que garantiza y otra que desarrolla. La primera se realiza en condiciones supervisadas, sin ayudas externas, y recae sobre las capacidades de la lista anterior. La segunda admite el uso declarado de estas herramientas y se orienta a desarrollar capacidades, incluida la de emplearlas con criterio.

El elemento que el modelo australiano aporta, y que la Escuela haría bien en conservar, es que la decisión sobre qué se sitúa en el carril supervisado se adopta en el nivel del programa. Si se deja a cada profesor, la garantía depende de criterios dispares y el estudiante recibe señales contradictorias.

El costo es documental y el plazo, de un año académico. La evidencia sostiene que el instrumento no supervisado perdió validez; la elección del modelo de dos carriles frente a otras respuestas posibles es una opción razonable y discutible.

2.3. Dejar de invertir en detección automática

La tercera medida consiste en no destinar recursos a sistemas de detección de texto generado, y en no fundar sanciones en sus resultados.

La evidencia es concluyente en ambas direcciones. La tasa media de falsos positivos del 61,3 % sobre ensayos de hablantes no nativos convierte a estas herramientas en un instrumento discriminatorio, y el 94 % de entregas no detectadas en el experimento de Reading muestra que tampoco cumplen la función para la que se adquieren. Doce instituciones de primer orden ya las desactivaron.

El costo es negativo, porque libera recursos, y el plazo es inmediato. Es la medida con respaldo empírico más directo de las cinco.

2.4. Evaluar la verificación de fuentes como competencia

La cuarta medida consiste en incorporar a las rúbricas, como elemento calificable y separado, la comprobación de que las fuentes citadas existen, dicen lo que se les atribuye y siguen vigentes.

Su fundamento es el descrito en el capítulo VIII. Esa comprobación se realizaba de manera incidental mientras el estudiante buscaba personalmente el material, y dejó de realizarse cuando la búsqueda se delegó en un sistema que produce texto plausible. Las cifras de contenido inventado en herramientas jurídicas comerciales, de entre el 17 % y el 33 %, y el registro acumulado de resoluciones judiciales que constatan citas inexistentes indican que la operación no se está ejecutando de manera fiable ni siquiera entre profesionales titulados.

El costo es bajo, porque consiste en modificar rúbricas existentes, y el plazo es de un año. La medida tiene además la particularidad de ser evaluable en el carril abierto, donde el uso de la herramienta está permitido.

2.5. Presupuestar horas de evaluación oral y diseño de tareas

La quinta medida consiste en incorporar al presupuesto una partida específica de horas docentes destinada a defensa oral, observación de desempeño y rediseño de tareas.

El fundamento de esta medida es aritmético. Los instrumentos que conservan valor probatorio consumen tiempo docente en proporción directa al número de estudiantes, mientras que los que lo perdieron eran los que permitían evaluar a muchos con poco tiempo. Una reforma evaluativa que no modifique la asignación de horas traslada el costo al profesor individual, y termina produciendo rúbricas nuevas sobre prácticas antiguas.

El costo es alto y el plazo, de dos a tres años. Es la medida que determina si las cuatro anteriores producen algún resultado, y es también la única que este informe no puede fundar en un estudio, porque ninguna de las instituciones examinadas ha documentado una inversión de esa naturaleza comparable a la que destina a licencias.

3. El riesgo principal y cómo reconocerlo a tiempo

El riesgo principal de una reforma evaluativa de este tipo no es pedagógico ni tecnológico, sino presupuestario. Las cuatro primeras medidas cuestan poco, se adoptan con relativa facilidad y producen documentos. La quinta cuesta, se posterga con facilidad y es la que convierte esos documentos en práctica.

El indicador que permite reconocer a tiempo ese fracaso es sencillo y puede vigilarse. Si en los presupuestos de los dos años siguientes a la adopción de las medidas no aparece una partida de horas docentes destinada a evaluación oral, diseño de tareas y observación de desempeño, la reforma habrá quedado en el documento que la declara.

4. El contexto chileno y una oportunidad propia

El informe que acompaña a este documento registra que ninguna de las once facultades de Derecho chilenas examinadas ha publicado una medición del efecto de sus iniciativas de inteligencia artificial sobre el aprendizaje de sus estudiantes. Este capítulo permite situar esa ausencia con precisión: no se trata de un rezago chileno respecto de una práctica extendida en otros países, porque la evidencia internacional sobre efecto es igualmente escasa y procede de un número reducido de equipos.

De ahí se sigue una consideración que la Escuela puede ponderar. Una medición de resultados de aprendizaje asociada a una intervención concreta, con grupo de comparación y realizada sobre uno o dos cursos, sería el primer trabajo de esa naturaleza en el conjunto de facultades chilenas examinadas en el informe complementario. La Escuela cuenta además con un antecedente propio, descrito en el capítulo VIII, que estableció el procedimiento en condiciones anteriores a la inteligencia artificial generativa.

La evidencia examinada en el capítulo VI sugiere, por último, el tipo de intervención que convendría medir. Las que produjeron resultados positivos verificados fueron pequeñas, con andamiajes diseñados por el profesor de la asignatura y restricciones explícitas sobre lo que la herramienta entrega. Las que produjeron deterioro fueron las de acceso libre y sin diseño.

XI. Conclusiones

La primera conclusión se refiere a la naturaleza del problema. Lo que la inteligencia artificial generativa alteró en la enseñanza universitaria no es principalmente la integridad académica, sino la validez de los instrumentos con que se acredita el aprendizaje. El experimento de la Universidad de Reading, en que el 94 % de entregas generadas por un modelo pasó sin detección dentro del sistema real de exámenes y obtuvo mejores calificaciones que los estudiantes, permite afirmarlo sobre una base experimental antes que sobre una impresión. La consecuencia alcanza al estudiante honesto tanto como al que infringe las reglas, porque en ambos casos el texto entregado ha dejado de informar sobre la capacidad de quien lo firma.

La segunda conclusión se refiere a las respuestas que no funcionan. La vía prohibitiva carece de viabilidad frente a una práctica que alcanza al 94 % de los estudiantes y que comprende operaciones de naturaleza muy distinta. La vía disciplinaria alcanza a siete casos por cada mil estudiantes, magnitud que no guarda relación con la extensión del uso. Y la detección automática produce falsos positivos que recaen de manera sistemática sobre quienes escriben con menor sofisticación lingüística, razón por la cual doce instituciones de primer orden la desactivaron. Las tres respuestas comparten un rasgo: tratan como problema de conducta lo que es un problema de diseño de la evaluación.

La tercera conclusión se refiere al efecto sobre el aprendizaje. La evidencia experimental disponible es escasa, reciente y en parte proveniente de poblaciones que no son universitarias, y su resultado más consistente es que el efecto depende del diseño de la tarea antes que del acceso a la herramienta. Un tutor con andamiajes y restricciones duplicó las ganancias de aprendizaje respecto del mejor método presencial disponible; el acceso libre al mismo tipo de modelo dejó a los estudiantes por debajo de quienes nunca lo habían tenido. De la conclusión se sigue una consecuencia de gasto, porque la inversión mayoritaria del sector, que es la licencia de acceso general, es la que menor respaldo empírico tiene de producir aprendizaje.

La cuarta conclusión se refiere al Derecho. La verificación de fuentes y la responsabilidad personal por lo firmado hacen de la formación jurídica un caso más expuesto que el de otras disciplinas, y ambas cosas están medidas: las herramientas jurídicas comerciales entregan contenido inventado entre el 17 % y el 33 % de las consultas, y el registro de resoluciones judiciales que constatan citas inexistentes alcanzaba mil novecientos ochenta y uno a fines de agosto de 2026. El efecto sobre el aprendizaje jurídico es además desigual: mejora el desempeño de los estudiantes con peor rendimiento previo y empeora el de los mejores, lo que reduce la dispersión del producto y, con ella, la información que el profesor obtenía de esa dispersión.

La quinta conclusión se refiere a las respuestas institucionales. De treinta instituciones examinadas en diez países, ninguna alcanza un cambio coordinado de currículo, evaluación, docencia, competencias, infraestructura y gobernanza, y ello en una muestra escogida por documentar iniciativas. El modelo dominante consiste en añadir contenido sobre la tecnología, que es la respuesta de menor costo institucional y la que menos relación guarda con el problema descrito. Un solo caso del conjunto actúa sobre la evaluación.

De las cinco conclusiones anteriores se siguen las medidas del capítulo X, cuatro de ellas documentales o de criterio y una presupuestaria. La distinción entre ambas clases importa más que su contenido, porque las primeras se adoptan con facilidad y la segunda determina si las primeras producen algún efecto.

Quedan abiertas tres cuestiones que este informe no puede resolver con la evidencia disponible.

La primera es el efecto de estas herramientas sobre la capacidad del estudiante en el mediano plazo. Ningún estudio de los examinados mide qué ocurre meses o años después de la intervención, y esa es la pregunta que más interesa a una escuela que forma profesionales.

La segunda es el momento adecuado de la carrera para incorporar el uso de estas herramientas. La operación de revisar un texto generado presupone el criterio que la operación de componerlo enseñaba a formar, sin que exista evidencia para determinar cuándo el estudiante ha adquirido ese criterio.

La tercera es el alcance de la reconstrucción formativa que el cambio en el mercado profesional exigirá. Si las tareas que formaban al abogado en sus primeros años de ejercicio dejan de existir como trabajo remunerado, la parte de esa formación que corresponde a la universidad aumenta, y ninguna institución examinada ha rediseñado su currículo con ese propósito.

Corresponde cerrar con una advertencia sobre la evidencia misma. La referencia más citada a favor de efectos positivos grandes de la inteligencia artificial sobre el aprendizaje fue retractada en abril de 2026, tras once meses de circulación y doscientas sesenta y seis citas, por agrupar estudios demasiado heterogéneos. Este informe procuró señalar en cada caso el diseño, la población y las limitaciones de los trabajos que emplea, y su propio contenido admite la misma revisión que aquí se recomienda aplicar a cualquier documento sobre esta materia.

Bibliografía

Se recogen únicamente las obras y fuentes citadas en el cuerpo del informe. Las referencias completas, con la indicación del diseño y la población de cada estudio, constan en las notas al pie del capítulo correspondiente.

1. Estudios experimentales

BASTANI, Hamsa; BASTANI, Osbert; SUNGU, Alp; GE, Haosen; KABAKCI, Özge, y MARIMAN, Rei (2025): experimento de campo sobre acceso a modelos de lenguaje en educación secundaria, realizado en Turquía con cerca de mil estudiantes. La revista publicó una corrección el 20 de agosto de 2025.

BEDNAR, Daniel; CLEVELAND, Charlotte; ERBSEN, Allan, y SCHWARCZ, Daniel (2026): estudio aleatorizado con cerca de cien estudiantes de Derecho y cuatro tareas secuenciales, sobre efecto de la exposición previa a inteligencia artificial en la comprensión posterior. Documento de trabajo no revisado por pares.

CHOI, Jonathan, y SCHWARCZ, Daniel (2023): «AI assistance in legal analysis: an empirical study», *Journal of Legal Education*. Estudio intrasujeto no aleatorizado con 48 estudiantes de Derecho.

DAHL, Matthew; MAGESH, Varun; SUZGUN, Mirac, y HO, Daniel (2024): «Large legal fictions: profiling legal hallucinations in large language models», *Journal of Legal Analysis*. Más de 800.000 consultas verificables.

DOSHI, Anil, y HAUSER, Oliver (2024): «Generative AI enhances individual creativity but reduces the collective diversity of novel content», *Science Advances*, julio de 2024.

KESTIN, Gregory; MILLER, Kelly; KLALES, Anna; MILBOURNE, Timothy, y PONTI, Gregorio (2025): «AI tutoring outperforms in-class active learning», *Scientific Reports*. Ensayo aleatorizado en el curso Physical Sciences 2 de Harvard, otoño de 2023, con unos 180 estudiantes.

MAGESH, Varun; SURANI, Faiz; DAHL, Matthew; SUZGUN, Mirac; MANNING, Christopher, y HO, Daniel (2025): «Hallucination-free? Assessing the reliability of leading AI legal research tools», *Journal of Empirical Legal Studies*. Evaluación de 202 consultas jurídicas preregistradas.

MODEL EVALUATION AND THREAT RESEARCH (2025): ensayo aleatorizado sobre productividad de desarrolladores experimentados, con 16 participantes y 246 tareas reales, julio de 2025.

SCARFE, Peter; WATCHAM, Kelly; CLARKE, Alasdair, y ROESCH, Etienne (2024): «A real-world test of artificial intelligence infiltration of a university examinations system», *PLOS ONE*.

SCHWARCZ, Daniel; MANNING, Sam; PRESCOTT, Patrick; BARRY, Shannon; CLEVELAND, Charlotte, y RICH, Joe (2026): ensayo controlado aleatorizado con 137 estudiantes de dos facultades de Derecho, *Journal of Law & Empirical Analysis*.

2. Estudios y análisis chilenos

- FAÚNDEZ-UGALDE, Antonio; MELLADO-SILVA, Rafael; ALDUNATE-LIZANA, Eduardo, y BENFELD ESCOBAR, Johann (2024): «La enseñanza-aprendizaje del derecho a través de asistentes virtuales: principales hallazgos en estudiantes universitarios de pregrado», *Revista Pedagogía Universitaria y Didáctica del Derecho*, vol. 11, n.º 1, pp. 31-48. Disponible en: <https://doi.org/10.5354/0719-5885.2024.69639>.
- OJEDA CIFUENTES, Diego Hernán (2026): *Informe sobre uso de IA en las Escuelas de Derecho, edición 2026*. Documento de trabajo para el Consejo de Profesores de la Escuela de Derecho de la Pontificia Universidad Católica de Valparaíso.

3. Encuestas y registros

- DIGITAL EDUCATION COUNCIL (2025 y 2026): encuestas a profesorado y estudiantado de educación superior. La oleada de 2025 recogió respuestas de 1.681 docentes de 52 instituciones en 28 países. Muestra autoseleccionada.
- EDUCAUSE (2026): informe sobre despliegues institucionales de inteligencia artificial en la educación superior estadounidense.
- HIGHER EDUCATION POLICY INSTITUTE (2024, 2025 y 2026): *Student Generative AI Survey*. Encuestas autoinformadas a estudiantes de grado del Reino Unido; la oleada de 2026 recogió 1.054 respuestas.
- CÁTEDRAS UNESCO y red UNITWIN (2025): encuesta a responsables de implantación de inteligencia artificial, con 400 respuestas en 90 países. Muestra no representativa.
- CHARLOTIN, Damien: base de datos de resoluciones judiciales en que un tribunal constató el uso de contenido jurídico inventado. Consulta al 28 de agosto de 2026.

4. Documentos institucionales y normativos

- CALIFORNIA STATE UNIVERSITY: despliegue institucional de inteligencia artificial generativa y encuesta interna de percepción, 2026.
- NATIONAL CONFERENCE OF BAR EXAMINERS: nuevo examen de acceso a la abogacía, con debut en julio de 2026.
- TECNOLÓGICO DE MONTERREY: modelo generativo institucional, lanzado el 28 de septiembre de 2023, y comunicaciones institucionales de 2025.
- TERTIARY EDUCATION QUALITY AND STANDARDS AGENCY (Australia): principios para la reforma de la evaluación ante la inteligencia artificial generativa.
- UNIVERSITY OF SYDNEY (2024): política de evaluación de dos carriles, formalizada en noviembre de 2024.

5. Trabajos retractados o corregidos, citados como antecedente

- WANG, Jin, y FAN, Wenxiang: metaanálisis sobre efectos de la inteligencia artificial en el aprendizaje, publicado en *Humanities and Social Sciences Communications* y retractado el 22 de abril de 2026. Sus cifras no se emplean en este informe.

MARTÍNEZ, Eric (2024): reanálisis del desempeño de GPT-4 en el examen de acceso a la abogacía estadounidense, *Artificial Intelligence and Law*.

Anexo. Solidez de la evidencia y nota sobre la elaboración

Este anexo reúne el detalle técnico del capítulo III. Su lectura no es necesaria para seguir el informe.

1. Los estudios que sostienen las conclusiones

La tabla registra los trabajos en que descansan las afirmaciones principales del documento, con su diseño, su población, su resultado y la advertencia que corresponde a cada uno. La columna de diseño permite ponderar el peso de cada resultado según el criterio del capítulo III.

Tabla 2. Estudios que sostienen las conclusiones del informe

Estudio	Diseño	Población	Resultado principal	Advertencia
Scarfe y otros (2024)	Experimento de campo con corrección ciega	5 módulos de Psicología, University of Reading	94 % de entregas generadas no detectadas, con notas superiores al promedio	Una sola institución y una sola disciplina
Kestin y otros (2025)	Ensayo aleatorizado	Unos 180 estudiantes de Harvard	El tutor con andamiajes duplicó las ganancias frente al aprendizaje activo	Tutor diseñado por expertos; no generalizable a herramientas comerciales
Bastani y otros (2025)	Experimento de campo	Cerca de 1.000 estudiantes de secundaria, Turquía	+48 % con la herramienta; -17 % al retirarla	Población escolar. La revista publicó una corrección el 20 de agosto de 2025
Choi y Schwarcz (2023)	Intrasujeto no aleatorizado	48 estudiantes de Derecho	Efecto desigual: +45 puntos percentiles en los de peor rendimiento previo, deterioro en los mejores	Muestra pequeña, sin aleatorización
Schwarcz y otros (2026)	Ensayo aleatorizado	137 estudiantes de dos facultades de Derecho	Productividad entre +34 % y +140 % en cinco de seis tareas	Sistema de common law; equipo coincidente con el estudio anterior
Magesh y otros (2025)	Evaluación preregistrada	202 consultas jurídicas	Contenido inventado entre 17 % y 33 % en herramientas comerciales	Herramientas y derecho estadounidenses
METR (2025)	Ensayo aleatorizado	16 desarrolladores, 246 tareas	19 % más lentos con asistencia, pese a percibir lo contrario	Sus autores lo califican hoy de documento histórico
Doshi y Hauser (2024)	Experimento	Escritura de relatos breves	Mejora individual y menor diversidad del conjunto	Tarea creativa, no académica
Faúndez-Ugalde y otros (2024)	Cuatro casos con grupo de control	16 a 56 estudiantes, PUCV	Mejora del grupo experimental en tres de cuatro casos	Asistentes anteriores a la IA generativa; muestras pequeñas

Wang y Fan	Metaanálisis	—	Retractado el 22 de abril de 2026	Sus cifras no se emplean en este informe
------------	--------------	---	-----------------------------------	--

Fuente: Elaboración propia. Los datos de diseño y población se verificaron contra la publicación original o su registro bibliográfico.

2. Qué se verificó y qué no

De los estudios de la tabla anterior, se contrastaron contra la publicación original o su registro bibliográfico los autores, el año, la revista, el diseño, la población y la cifra principal. Ese contraste se realizó de manera individual y su resultado consta en la tabla.

No se verificaron de la misma manera las cifras procedentes de encuestas institucionales ni de comunicaciones de universidades, que se emplean tal como sus emisores las publicaron. El informe señala en cada caso esa condición y la naturaleza autoinformada o autoseleccionada de la muestra.

Un conjunto de fuentes del corpus de base quedó sin verificación individual a la fecha de cierre. El informe no apoya en ellas ninguna afirmación del cuerpo.

3. Límites del procedimiento

El documento no es una revisión sistemática, según se indica en el capítulo III. No hubo protocolo de búsqueda declarado con antelación, registro de la estrategia, criterios formalizados de inclusión y exclusión ni doble revisión independiente. La consecuencia es doble: no cabe descartar la omisión de trabajos relevantes, ni un sesgo de selección en favor de los resultados con mayor difusión pública.

El sesgo de publicación afecta de manera particular a esta literatura. Los estudios que informan efectos positivos de la inteligencia artificial sobre el aprendizaje reciben mayor difusión que los que informan efectos nulos o negativos, y la retractación del metaanálisis más citado del campo muestra que esa difusión puede sostenerse durante meses sobre una base defectuosa.

El alcance geográfico constituye un tercer límite. La evidencia experimental sobre educación jurídica procede en su totalidad de los Estados Unidos, y en su mayor parte de un mismo equipo de investigación. Su traslado a la formación jurídica chilena es una inferencia razonable que el informe formula como tal.

4. Nota sobre la elaboración del documento

El informe se preparó con apoyo de herramientas de inteligencia artificial generativa en tareas de búsqueda preliminar, ordenación del material reunido y redacción de versiones de trabajo.

El autor realizó personalmente las siguientes operaciones. Verificó las cifras, el diseño y la población de cada estudio de la tabla del apartado 1 contra su publicación original o su registro bibliográfico. Comprobó la vigencia de la retractación del metaanálisis de Wang y Fan y de la corrección publicada sobre el experimento de Bastani y otros. Redactó las

conclusiones del capítulo XI y las cinco medidas del capítulo X, y decidió qué afirmaciones el documento sostiene y cuáles presenta como opción discutible.

Esta declaración se incluye porque el documento recomienda a la Escuela exigir la declaración del uso de estas herramientas en los trabajos de sus estudiantes, y esa exigencia carecería de fundamento si el propio informe no la cumpliera.